

Tarea_2_Godoy_Xavier

June 5, 2026

1 Tarea 2

1.1 Xavier Godoy Cerda - 2022451939

1.1.1 Universidad de Concepción

Dataset: dataset_prueba.csv — Datos de movilidad laboral y restricciones COVID-19 a nivel de ciudad (DE, ES, FR, IT, SE). **Variable dependiente:** workplaces — Variación porcentual de-trended en la movilidad a lugares de trabajo respecto al baseline pre-pandemia. **Objetivo:** Estimar el efecto causal de las restricciones gubernamentales sobre la movilidad laboral.

1.2 Pregunta 1: Carga, descripción y limpieza de datos

```
[9]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import missingno as msno
import statsmodels.api as sm
import linearmodels.panel as lmp
import numpy.linalg as la
from scipy import stats
import warnings
warnings.filterwarnings("ignore")

df = pd.read_csv('dataset_prueba.csv')
df['date'] = pd.to_datetime(df['date'])

print('Shape del dataset:', df.shape)
print()
print('--- Tipos de Variables ---')
display(df.dtypes)
```

Shape del dataset: (12040, 41)

--- Tipos de Variables ---

iso_code	object
date	datetime64[ns]
retail_and_recreation_percent_change_from_baseline	float64
grocery_and_pharmacy_percent_change_from_baseline	float64
parks_percent_change_from_baseline	float64
transit_stations_percent_change_from_baseline	float64
workplaces_raw	float64
residential_percent_change_from_baseline	float64
trend	float64
workplaces	float64
Valor_Stringency_Index	float64
Valor_GovernmentResponseIndex	float64
Valor_EconomicSupportIndex	float64
Valor_Containment_Health_index	float64
workplace_closing	float64
daily_cases	float64
d2	int64
d1	int64
d3	int64
d4	int64
d5	int64
d6	int64
week	int64
year	int64
CODE	object
NAME	object
Population	float64
agriculture	float64
industry	float64
construction	float64
edu2	float64
edu3	float64
age_dependency	float64
old_age_dependency	float64
young_age_dependency	float64
sex_ratio	float64
unemp	float64
f_unemp	float64
m_unemp	float64
foreigners	float64
country	object
dtype:	object

```
[10]: print('--- Valores Faltantes por Columna ---')
missing = df.isnull().sum()
missing = missing[missing > 0]
print(missing)
```

```

print()
print(f'Total de observaciones: {len(df):,}')
print(f'Porcentaje faltante edu2: {missing["edu2"]/len(df)*100:.1f}%')
print(f'Porcentaje faltante edu3: {missing["edu3"]/len(df)*100:.1f}%')

fig, ax = plt.subplots(figsize=(14, 5))
msno.matrix(df, ax=ax, fontsize=9, color=(0.3, 0.5, 0.8))
ax.set_title('Patrón de Valores Faltantes en el Dataset', fontsize=13, pad=10)
plt.tight_layout()
plt.show()

```

--- Valores Faltantes por Columna ---

edu2 5460


edu3 5460

dtype: int64

Total de observaciones: 12,040

Porcentaje faltante edu2: 45.3%

Porcentaje faltante edu3: 45.3%



Análisis de datos faltantes:

Solo edu2 y edu3 tienen valores faltantes (5.460 observaciones cada una, un 45% del total). Como incluirlas reduciría la muestra a la mitad y los modelos dejarían de ser comparables entre sí, se eliminan.

```

[ ]: # Variables clave para el análisis
key_vars = [
    'workplaces', 'workplaces_raw',
    'Valor_Stringency_Index', 'Valor_GovernmentResponseIndex',
    'Valor_Containment_Health_index', 'Valor_EconomicSupportIndex',
    'workplace_closing', 'daily_cases',
    'age_dependency', 'unemp', 'foreigners', 'industry',
    'agriculture', 'construction', 'Population'
]

```

```
]
print('--- Estadísticas descriptivas de variables clave ---')
display(df[key_vars].describe().T.round(3))
```

--- Estadísticas Descriptivas de Variables Clave ---

	count	mean	std	min	25% \
workplaces	12040.0	-18.667	11.801	-76.787	-24.358
workplaces_raw	12040.0	-25.003	14.681	-87.000	-32.400
Valor_Stringency_Index	12040.0	27.486	29.836	0.000	0.000
Valor_GovernmentResponseIndex	12040.0	30.637	30.245	0.000	0.000
Valor_Containment_Health_index	12040.0	30.592	29.943	0.000	0.000
Valor_EconomicSupportIndex	12040.0	30.955	36.364	0.000	0.000
workplace_closing	12040.0	0.851	0.997	0.000	0.000
daily_cases	12040.0	2355.733	3154.914	0.000	0.037
age_dependency	12040.0	0.654	0.073	0.520	0.609
unemp	12040.0	12.221	8.265	3.000	6.000
foreigners	12040.0	8.146	2.992	2.000	6.000
industry	12040.0	0.115	0.044	0.037	0.081
agriculture	12040.0	0.007	0.010	0.000	0.001
construction	12040.0	0.053	0.018	0.018	0.037
Population	12040.0	745.474	1277.342	201.048	246.794

	50%	75%	max
workplaces	-16.820	-10.884	19.058
workplaces_raw	-22.800	-14.400	6.600
Valor_Stringency_Index	15.858	53.420	93.520
Valor_GovernmentResponseIndex	32.030	60.160	81.306
Valor_Containment_Health_index	36.610	59.230	85.420
Valor_EconomicSupportIndex	0.000	75.000	100.000
workplace_closing	0.000	2.000	3.000
daily_cases	632.010	3815.644	22203.314
age_dependency	0.651	0.682	0.837
unemp	8.000	18.000	36.000
foreigners	9.000	11.000	15.000
industry	0.107	0.149	0.233
agriculture	0.004	0.011	0.071
construction	0.053	0.070	0.153
Population	346.790	620.523	10274.884

```
[ ]: fig, axes = plt.subplots(2, 3, figsize=(16, 8))

vars_plot = [
    ('workplaces', 'Movilidad Laboral (%, de-trended)'),
    ('Valor_Stringency_Index', 'Stringency Index (0-100)'),
    ('daily_cases', 'Casos Diarios (sin transformar)'),
    ('unemp', 'Tasa de Desempleo (%)'),
```


```

('age_dependency', 'Dependencia Etaria'),
('Valor_Containment_Health_index', 'Containment-Health Index'),
]

for ax, (var, label) in zip(axes.flatten(), vars_plot):
    sns.histplot(df[var].dropna(), ax=ax, kde=True, bins=40,
                 color='steelblue', edgecolor='white', linewidth=0.3)
    ax.set_title(label, fontsize=11)
    ax.set_xlabel('')

plt.suptitle('Distribución de variables clave', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()

```



```

[13]: # Stringency promedio por país
print('--- Stringency Index Promedio por País ---')
print(df.groupby('country')['Valor_Stringency_Index'].
      .agg(['mean', 'std', 'min', 'max']).round(2))

print()
print('--- Movilidad Laboral Promedio por País ---')
print(df.groupby('country')['workplaces'].agg(['mean', 'std']).round(2))

# Evolución temporal de Stringency por país
fig, ax = plt.subplots(figsize=(14, 5))
for country, grp in df.groupby('country'):
    weekly = grp.groupby('week')['Valor_Stringency_Index'].mean()
    ax.plot(weekly.index, weekly.values, label=country, linewidth=2)

```

```

ax.set_xlabel('Semana')
ax.set_ylabel('Stringency Index promedio')
ax.set_title('Evolución del Stringency Index por País (promedio ciudades)',
             ↪fontsize=12)
ax.legend(title='País')
ax.grid(alpha=0.3)
plt.tight_layout()
plt.show()


```

--- Stringency Index Promedio por País ---

	mean	std	min	max
country				
DE	0.00	0.00	0.00	0.00
ES	49.72	20.22	8.33	85.19
FR	46.21	22.06	5.56	87.96
IT	56.79	21.84	15.51	93.52
SE	40.15	23.19	5.56	71.09

--- Movilidad Laboral Promedio por País ---

	mean	std
country		
DE	-16.03	9.70
ES	-20.05	13.38
FR	-21.50	12.91
IT	-20.72	12.52
SE	-23.43	10.60



```

[14]: # --- Limpieza ---
df.drop(columns=['edu2', 'edu3'], inplace=True)

# Log-transformación de daily_cases (distribución muy sesgada a la derecha)
df['log_cases'] = np.log(df['daily_cases'] + 1) # +1 para evitar log(0)

```

```
print('Limpieza completada.')
print('Shape final:', df.shape)
print('Variables faltantes restantes:', df.isnull().sum().sum())
```

Limpieza completada.
 Shape final: (12040, 40)
 Variables faltantes restantes: 0

1.2.1 Conclusiones pregunta 1

Tipos de variables: las variables de movilidad e índices de política son `float64`, las temporales (`week`, `year`) son `int64`, y los identificadores (`iso_code`, `CODE`, `NAME`, `country`) son `object`.

Distribuciones y estadísticas clave: - `workplaces` tiene media de -18.67 pp y std de 11.8 , con distribución aproximadamente normal centrada en valores negativos. Esto confirma que la pandemia redujo sistemáticamente la movilidad laboral en todas las ciudades. - `Valor_Stringency_Index` tiene media de 27.49 pero std de 29.84 , lo que delata una distribución bimodal: Alemania tiene `Stringency` = 0 durante todo el período, mientras España, Italia, Francia y Suecia alcanzan valores entre 40 y 94. Esta variación entre países es lo que nos permite identificar el efecto de las restricciones. - `daily_cases` está muy sesgado a la derecha (media 2.356 , max 22.203), por lo que se aplica transformación logarítmica (`log_cases`) para reducir el efecto de valores extremos.

Limpieza aplicada: eliminación de `edu2` y `edu3` (45% de missings), y creación de `log_cases` = `log(daily_cases + 1)` para manejar la asimetría y los ceros.

1.3 Pregunta 2: Pooled OLS

Estimamos un **Pooled OLS** como punto de partida. Este modelo trata todas las observaciones como si fueran independientes entre sí, ignorando que tenemos la misma ciudad observada durante 140 semanas. Es el más simple, pero también el más sesgado si existen diferencias no observadas entre ciudades que estén correlacionadas con el nivel de restricciones.

Variables seleccionadas: - Dependiente: `workplaces` (movilidad laboral, de-trended) - `Valor_Stringency_Index`: el índice de restricciones gubernamentales, que es la variable de interés principal - `Valor_Containment_Health_index`: mide medidas de contención y salud (cuarentenas, testeo), complementario al `Stringency` - `log_cases`: controla el efecto de que la gente reduce movilidad voluntariamente por el miedo al contagio, no solo por las reglas - `workplace_closing`: orden directa de cierre de lugares de trabajo (0 a 3) - `age_dependency`, `unemp`, `foreigners`, `industry`: características estructurales de cada ciudad que afectan la movilidad de base - `week`, `year`: capturan tendencias temporales comunes (olas pandémicas, estacionalidad)

```
[15]: # Índice del panel: entidad = CODE (ciudad), tiempo = date
      # ¡IMPORTANTE! Usar CODE (ciudad), NO iso_code (región que agrupa varias
      # ciudades)
      df_panel = df.set_index(['CODE', 'date']).sort_index()

      # Variable dependiente
```

```

y = df_panel['workplaces']

# Regresores
X = df_panel[[
    'Valor_Stringency_Index',
    'Valor_Containment_Health_index',
    'log_cases',
    'workplace_closing',
    'age_dependency',
    'unemp',
    'foreigners',
    'industry',
    'week',
    'year'
]]
X = sm.add_constant(X)

# Pooled OLS con errores robustos a heterocedasticidad
# cov_type='robust': necesario porque los residuos de una misma ciudad
# están autocorrelacionados en el tiempo (no son i.i.d.)
mco = lmp.PanelOLS(y, X).fit(cov_type='robust')
print(mco)

```

PanelOLS Estimation Summary

```

=====
Dep. Variable:          workplaces    R-squared:                0.3433
Estimator:              PanelOLS      R-squared (Between):      0.3469
No. Observations:      12040          R-squared (Within):      0.3427
Date:                  Sun, May 24 2026 R-squared (Overall):     0.3433
Time:                  23:41:31        Log-likelihood            -4.427e+04
Cov. Estimator:        Robust

                               F-statistic:            628.76
Entities:              86             P-value              0.0000
Avg Obs:               140.00         Distribution:         F(10,12029)
Min Obs:               140.00
Max Obs:               140.00         F-statistic (robust):   430.98
                               P-value              0.0000
Time periods:          140           Distribution:         F(10,12029)
Avg Obs:               86.000
Min Obs:               86.000
Max Obs:               86.000

```

Parameter Estimates

```

=====
=====

```

		Parameter	Std. Err.	T-stat	P-value
Lower CI	Upper CI				

```

-----

```

const		9304.4	649.89	14.317	0.0000
8030.5	1.058e+04				
Valor_Stringency_Index		-0.3561	0.0178	-19.978	0.0000
-0.3911	-0.3212				
Valor_Containment_Health_index		0.2541	0.0179	14.176	0.0000
0.2189	0.2892				
log_cases		-0.0971	0.0291	-3.3403	0.0008
-0.1541	-0.0401				
workplace_closing		-0.8997	0.2908	-3.0943	0.0020
-1.4697	-0.3298				
age_dependency		6.7255	1.5384	4.3718	0.0000
3.7101	9.7410				
unemp		-0.0309	0.0183	-1.6878	0.0915
-0.0669	0.0050				
foreigners		-0.4016	0.0373	-10.781	0.0000
-0.4746	-0.3286				
industry		-6.2798	2.1452	-2.9273	0.0034
-10.485	-2.0747				
week		0.1579	0.0070	22.713	0.0000
0.1443	0.1716				
year		-4.6171	0.3218	-14.348	0.0000
-5.2478	-3.9863				
=====					
=====					

1.3.1 Interpretación Pooled OLS

1. Ajuste global: El R^2 es 0.343, lo que indica que el modelo explica el 34.3% de la variación en movilidad laboral. Sin embargo, este valor está algo inflado porque el Pooled OLS usa tanto diferencias entre ciudades como cambios en el tiempo para ajustarse, lo que no es necesariamente una buena identificación causal.

2. Variables significativas:

- **Valor_Stringency_Index** (coef = -0.356 , $p < 0.001$): significativo y con el signo esperado. Un aumento de 10 puntos en el Stringency Index se asocia a una reducción de **3.56 pp** en la movilidad laboral, manteniendo el resto constante.
- **Valor_Containment_Health_index** (coef = 0.254 , $p < 0.001$): tiene signo positivo, lo que puede parecer contradictorio. Esto probablemente refleja colinealidad con el Stringency: cuando se controla por Stringency, el índice de contención captura las medidas más suaves (recomendaciones, testeo) que no reducen movilidad directamente.
- **log_cases** (coef = -0.097 , $p < 0.001$): cada 1% de aumento en los casos diarios reduce la movilidad en aproximadamente 0.1 pp. Las personas reducen movilidad por el riesgo percibido, independiente de las restricciones formales.
- **workplace_closing** (coef = -0.900 , $p = 0.002$): las órdenes directas de cierre laboral tienen un efecto adicional de -0.9 pp por cada nivel de cierre, por encima del efecto del Stringency

general.

- **foreigners** (coef = -0.402 , $p < 0.001$): ciudades con más trabajadores extranjeros tienen menor movilidad laboral en promedio, posiblemente por su concentración en sectores más afectados por las restricciones.
- **industry** (coef = -6.280 , $p = 0.003$): ciudades más industriales muestran mayor reducción de movilidad bajo restricciones, consistente con que estos trabajadores tienen menor posibilidad de teletrabajar.
- **unemp** (coef = -0.031 , $p = 0.091$): no es significativo al 5%, por lo que no podemos concluir un efecto claro del desempleo previo sobre la movilidad.

3. Limitación del modelo: El Pooled OLS asume que no existen diferencias sistemáticas no observadas entre ciudades. Esto es difícil de sostener: una ciudad más industrial o con mayor densidad probablemente tenga tanto más restricciones como diferente movilidad de base. Esas características no medidas sesgan los coeficientes.

1.4 Pregunta 3: Fixed Effects (Efectos fijos)

El modelo de **Efectos fijos (FE)** corrige el problema principal del Pooled OLS: controla por todas las características de cada ciudad que no cambian en el tiempo, ya sean observables o no (densidad urbana, cultura de cumplimiento, estructura económica, etc.). Lo hace calculando la variación de cada variable respecto a la media propia de cada ciudad, de forma que los coeficientes miden el efecto de los cambios *dentro de cada ciudad* a lo largo del tiempo.

Las variables demográficas (`age_dependency`, `unemp`, `foreigners`, `industry`) no cambian entre semanas para una misma ciudad, por lo que son colineales con los efectos fijos y quedan absorbidas automáticamente — no aparecen en los resultados.

```
[21]: # Regresores para FE: excluir variables time-invariant (serán absorbidas por los FE)
X_fe = df_panel[[
    'Valor_Stringency_Index',
    'Valor_Containment_Health_index',
    'log_cases',
    'workplace_closing',
    'week',
    'year'
]]
X_fe = sm.add_constant(X_fe)

# entity_effects=True: incluye un intercepto específico para cada ciudad
# drop_absorbed=True: elimina automáticamente variables perfectamente colineales con los FE
fe = lmp.PanelOLS(y, X_fe, entity_effects=True, drop_absorbed=True).fit(cov_type='robust')
print(fe)
```

PanelOLS Estimation Summary

=====

Dep. Variable:	workplaces	R-squared:	0.3482
Estimator:	PanelOLS	R-squared (Between):	-0.5593
No. Observations:	12040	R-squared (Within):	0.3482
Date:	Mon, May 25 2026	R-squared (Overall):	0.2202
Time:	00:04:14	Log-likelihood	-4.331e+04
Cov. Estimator:	Robust		
		F-statistic:	1064.0
Entities:	86	P-value	0.0000
Avg Obs:	140.00	Distribution:	F(6,11948)
Min Obs:	140.00		
Max Obs:	140.00	F-statistic (robust):	711.61
		P-value	0.0000
Time periods:	140	Distribution:	F(6,11948)
Avg Obs:	86.000		
Min Obs:	86.000		
Max Obs:	86.000		

Parameter Estimates

		Parameter	Std. Err.	T-stat	P-value
Lower CI	Upper CI				

const		1.011e+04	649.54	15.565	0.0000
8836.9	1.138e+04				
Valor_Stringency_Index		-0.5041	0.0254	-19.842	0.0000
-0.5539	-0.4543				
Valor_Containment_Health_index		0.5425	0.0444	12.225	0.0000
0.4555	0.6295				
log_cases		-0.2733	0.0314	-8.6976	0.0000
-0.3349	-0.2117				
workplace_closing		-1.2561	0.2894	-4.3406	0.0000
-1.8233	-0.6889				
week		0.1522	0.0067	22.563	0.0000
0.1390	0.1654				
year		-5.0173	0.3217	-15.595	0.0000
-5.6479	-4.3867				
=====					
=====					

F-test for Poolability: 27.365
P-value: 0.0000
Distribution: F(85,11948)

Included effects: Entity

1.4.1 Interpretación Fixed Effects

1. Ajuste global: El within R^2 es 0.348, interpretado como la fracción de variación *temporal dentro de cada ciudad* que explican las restricciones. El R^2 between es negativo (-0.559), lo que es normal en FE: el modelo no intenta explicar diferencias entre ciudades, solo cambios en el tiempo.

El **F-test de poolabilidad** ($F = 27.37$, $p < 0.001$) confirma que los efectos fijos de ciudad son conjuntamente significativos, es decir, que las ciudades tienen niveles base de movilidad muy distintos entre sí y que ignorarlos (como hace el Pooled OLS) genera sesgo.

2. Variables significativas:

- **Valor_Stringency_Index** (coef = -0.504 , $p < 0.001$): el efecto aumenta en magnitud respecto al Pooled OLS (de -0.356 a -0.504). Esto significa que el Pooled OLS estaba subestimando el efecto de las restricciones. Un aumento de 10 puntos en el Stringency reduce la movilidad en **5.04 pp** dentro de una misma ciudad.
- **Valor_Containment_Health_index** (coef = 0.543 , $p < 0.001$): el coeficiente positivo se mantiene y aumenta. Controlando por los efectos fijos de ciudad, las medidas de contención y salud muestran un efecto diferenciado del Stringency puro.
- **log_cases** (coef = -0.273 , $p < 0.001$): el efecto de los casos sobre la reducción voluntaria de movilidad también aumenta respecto al Pooled OLS.
- **workplace_closing** (coef = -1.256 , $p < 0.001$): el efecto de las órdenes de cierre sube a -1.26 pp por nivel, más fuerte que en el Pooled OLS.

3. Comparación con Pooled OLS: todos los coeficientes son más grandes en magnitud en FE, lo que sugiere que el Pooled OLS estaba atenuando los efectos porque mezclaba la variación entre ciudades (sesgada) con la variación dentro de ciudad.

1.5 Pregunta 4: Random Effects (Efectos aleatorios)

El modelo de **Efectos aleatorios (RE)** también incluye un efecto específico por ciudad, pero asume que ese efecto no está correlacionado con las variables independientes. Si esto se cumple, RE es más eficiente que FE porque usa tanto la variación dentro de ciudad como la variación entre ciudades. La ventaja adicional es que permite estimar el efecto de las variables demográficas que FE absorbe.

Usamos el mismo conjunto de variables que el Pooled OLS.

```
[22]: # Random Effects usa el mismo X que Pooled OLS (incluye variables
      ↪time-invariant)
model_re = lmp.RandomEffects(y, X)
re = model_re.fit(cov_type='robust')
print(re)
print()
print('--- Descomposición de Varianza ---')
print(re.variance_decomposition)
```

RandomEffects Estimation Summary

```
=====
Dep. Variable:                workplaces    R-squared:                0.3460
```

```

Estimator:           RandomEffects   R-squared (Between):           0.1603
No. Observations:    12040           R-squared (Within):           0.3474
Date:                Mon, May 25 2026 R-squared (Overall):          0.3210
Time:                00:04:20         Log-likelihood                 -4.337e+04
Cov. Estimator:      Robust

                               F-statistic:           636.43
Entities:            86           P-value           0.0000
Avg Obs:             140.00       Distribution:       F(10,12029)
Min Obs:             140.00
Max Obs:             140.00       F-statistic (robust):    413.51
                               P-value           0.0000
Time periods:        140         Distribution:       F(10,12029)
Avg Obs:             86.000
Min Obs:             86.000
Max Obs:             86.000

```

Parameter Estimates

		Parameter	Std. Err.	T-stat	P-value
Lower CI	Upper CI				

const		9769.6	628.83	15.536	0.0000
8536.9	1.1e+04				
Valor_Stringency_Index		-0.4645	0.0220	-21.100	0.0000
-0.5077	-0.4214				
Valor_Containment_Health_index		0.4502	0.0335	13.457	0.0000
0.3846	0.5158				
log_cases		-0.2060	0.0296	-6.9514	0.0000
-0.2640	-0.1479				
workplace_closing		-1.0723	0.2812	-3.8133	0.0001
-1.6235	-0.5211				
age_dependency		-8.1296	6.3013	-1.2901	0.1970
-20.481	4.2220				
unemp		-0.2345	0.0741	-3.1654	0.0016
-0.3797	-0.0893				
foreigners		-0.4912	0.1509	-3.2556	0.0011
-0.7870	-0.1955				
industry		-11.219	9.3840	-1.1955	0.2319
-29.613	7.1753				
week		0.1528	0.0067	22.920	0.0000
0.1397	0.1658				
year		-4.8415	0.3112	-15.555	0.0000
-5.4516	-4.2314				
=====					
=====					

```

--- Descomposición de Varianza ---
Effects                11.828531
Residual               78.448903
Percent due to Effects    0.131024
Name: Variance Decomposition, dtype: float64

```

1.5.1 Interpretación Random Effects

1. Coeficientes: los resultados de RE son un promedio ponderado entre FE y el estimador between. Por eso, los coeficientes quedan entre los del Pooled OLS y los del FE. Por ejemplo, `Valor_Stringency_Index` pasa de -0.356 (Pooled) a -0.465 (RE) a -0.504 (FE).

- **Valor_Stringency_Index** (coef = -0.465 , $p < 0.001$): 10 puntos más de Stringency reducen la movilidad en **4.65 pp**.
- **workplace_closing** (coef = -1.072 , $p < 0.001$): sigue siendo significativo y negativo.
- **unemp** (coef = -0.235 , $p = 0.002$): ahora sí es significativo (era no significativo en Pooled OLS). Ciudades con mayor desempleo previo tienen menor movilidad laboral.
- **age_dependency** (coef = -8.130 , $p = 0.197$): no es significativo. Las diferencias en dependencia etaria entre ciudades no tienen un efecto claro sobre la movilidad.

2. Descomposición de varianza: la varianza debida a los efectos individuales de ciudad es 11.83, frente a una varianza residual de 78.45 (13.1% del error total). Esto indica que los efectos fijos de ciudad explican una fracción moderada de la varianza no explicada, pero que la mayor parte de la variación es temporal (dentro de ciudad), lo que es consistente con el período de pandemia.

3. ¿Es válido el supuesto de RE? El supuesto clave, que los efectos individuales no están correlacionados con los regresores, es difícil de sostener aquí: es razonable pensar que las ciudades con más restricciones (mayor Stringency) son sistemáticamente distintas en dimensiones no observadas. La decisión formal la tomamos en la Pregunta 5 con el Test de Hausman.

1.6 Pregunta 5: Comparación de modelos y test de Hausman

Comparamos los tres modelos con `lmpr.compare()` para ver cómo cambian los coeficientes según el modelo. Luego aplicamos el **test de Hausman** para decidir formalmente entre FE y RE.

El test compara los coeficientes de FE y RE: si son muy distintos entre sí, significa que el supuesto de RE está violado (los efectos de ciudad sí están correlacionados con las restricciones) y debemos usar FE.

- **H**: los efectos individuales no están correlacionados con los regresores $\rightarrow$ RE es válido
- **H**: sí están correlacionados $\rightarrow$ RE está sesgado $\rightarrow$ usar FE

```

[23]: # Tabla comparativa de los tres modelos
print('=== Comparación de Modelos ===')
print(lmpr.compare({'Pooled OLS': mco, 'FE': fe, 'RE': re}))

```

```

=== Comparación de Modelos ===

                                Model Comparison
=====
==

```

RE	Pooled OLS	FE

--		
Dep. Variable	workplaces	workplaces
workplaces		
Estimator	PanelOLS	PanelOLS
RandomEffects		
No. Observations	12040	12040
12040		
Cov. Est.	Robust	Robust
Robust		
R-squared	0.3433	0.3482
0.3460		
R-Squared (Within)	0.3427	0.3482
0.3474		
R-Squared (Between)	0.3469	-0.5593
0.1603		
R-Squared (Overall)	0.3433	0.2202
0.3210		
F-statistic	628.76	1064.0
636.43		
P-value (F-stat)	0.0000	0.0000
0.0000		
=====	=====	=====
=====		
const	9304.4	1.011e+04
9769.6		
	(14.317)	(15.565)
(15.536)		
Valor_Stringency_Index	-0.3561	-0.5041
-0.4645		
	(-19.978)	(-19.842)
(-21.100)		
Valor_Containment_Health_index	0.2541	0.5425
0.4502		
	(14.176)	(12.225)
(13.457)		
log_cases	-0.0971	-0.2733
-0.2060		
	(-3.3403)	(-8.6976)
(-6.9514)		
workplace_closing	-0.8997	-1.2561
-1.0723		
	(-3.0943)	(-4.3406)
(-3.8133)		
age_dependency	6.7255	
-8.1296		

	(4.3718)	
(-1.2901)		
unemp	-0.0309	
-0.2345		
	(-1.6878)	
(-3.1654)		
foreigners	-0.4016	
-0.4912		
	(-10.781)	
(-3.2556)		
industry	-6.2798	
-11.219		
	(-2.9273)	
(-1.1955)		
week	0.1579	0.1522
0.1528		
	(22.713)	(22.563)
(22.920)		
year	-4.6171	-5.0173
-4.8415		
	(-14.348)	(-15.595)
(-15.555)		

```

=====
=====
Effects                                     Entity
-----
--

```

T-stats reported in parentheses

```

[ ]: # Test de Hausman

def hausman(fe, re):
    """
    Estadístico de Hausman para contraste FE vs RE.
    H0: efectos individuales no correlacionados con regresores → RE consistente
    H1: existe correlación → RE inconsistente → usar FE
    """
    common = fe.params.index.intersection(re.params.index)
    diff = fe.params[common] - re.params[common]
    psi = fe.cov.loc[common, common] - re.cov.loc[common, common]
    dof = len(common)
    W = diff.dot(la.pinv(psi)).dot(diff) # pinv: más estable que inv
    pval = stats.chi2.sf(W, dof)
    return W, dof, pval

# Estimar FE y RE con los mismos regresores time-varying (sin demográficos)

```



```

X_hausman = df_panel[[
    'Valor_Stringency_Index',
    'Valor_Containment_Health_index',
    'log_cases',
    'workplace_closing',
    'week',
    'year'
]]
X_hausman = sm.add_constant(X_hausman)

fe_h = lmp.PanelOLS(y, X_hausman, entity_effects=True, drop_absorbed=True).
    fit(cov_type='robust')
re_h = lmp.RandomEffects(y, X_hausman).fit(cov_type='robust')

W, dof, pval = hausman(fe_h, re_h)
print('=== Test de Hausman ===')
print(f'Estadístico chi² : {W:.4f}')
print(f'Grados de libertad: {dof}')
print(f'P-valor : {pval:.6f}')
print()
if pval < 0.05:
    print('Conclusión: Se rechaza H0 (p < 0.05) → Los efectos individuales
    están
    correlacionados con los regresores → RE es inconsistente → Usar FE o
    CRE.')
else:
    print('Conclusión: No se rechaza H0 → RE es consistente y más eficiente que
    FE.')

```

```

=== Test de Hausman ===
Estadístico chi² : 28.0898
Grados de libertad: 7
P-valor : 0.000212

```

Conclusión: Se rechaza H0 (p < 0.05) → Los efectos individuales están correlacionados con los regresores → RE es inconsistente → Usar FE o CRE.

1.6.1 Interpretación, comparación y test de Hausman

1. Comparativa: los tres modelos coinciden en el signo y la significancia de las variables clave. El coeficiente de `Valor_Stringency_Index` va de -0.356 (Pooled OLS) a -0.465 (RE) a -0.504 (FE), mostrando que el Pooled OLS subestimaba el efecto de las restricciones. Las variables **robustas** (significativas en los tres modelos) son: - `Valor_Stringency_Index`, `Valor_Containment_Health_index`, `log_cases`, `workplace_closing`, `week`, `year`.

2. Test de Hausman: con un p-valor muy pequeño (< 0.05) se rechaza H, lo que indica que los efectos individuales de ciudad sí están correlacionados con las restricciones. Esto tiene sentido: las ciudades que aplicaron más restricciones son sistemáticamente distintas (más densas,

más industriales, mayor capacidad institucional), y esas diferencias afectan también la movilidad. RE no puede controlar eso y sus coeficientes son inconsistentes.

Modelo preferido preliminar: FE, dado el resultado del Hausman.

1.7 Pregunta 6: Correlated Random Effects (CRE / Mundlak)

El modelo **CRE** (Mundlak) es una alternativa a FE que captura explícitamente la correlación entre los efectos individuales de ciudad y los regresores. La idea es simple: se añade la media temporal de cada regresor (calculada para cada ciudad) como variable adicional en el modelo RE. Con esto logramos dos cosas: 1. El coeficiente de la variable original mide el efecto *within* (igual al FE). 2. El coeficiente de la media mide el efecto *between* (diferencias estructurales entre ciudades).

La ventaja sobre FE puro es que CRE permite estimar el efecto de las variables demográficas time-invariant.

Nota técnica: `week` y `year` se excluyen del cálculo de medias porque en un panel balanceado su media es idéntica para todas las ciudades (constante), lo que generaría colinealidad perfecta con el intercepto.

```
[ ]: # Paso 1: Variables que varían en el tiempo
time_varying = [
    'Valor_Stringency_Index',
    'Valor_Containment_Health_index',
    'log_cases',
    'workplace_closing',
]

# Paso 2: Calcular la media temporal de cada variable para cada ciudad (CODE)
# transform('mean') devuelve un DataFrame con el mismo índice que df_panel
# (no colapsa las filas), lo que permite concatenarlo directamente
Xm = df_panel[time_varying].groupby(level='CODE').transform('mean')
Xm.columns = ['m_' + c for c in Xm.columns]

# Paso 3: Construir X aumentado con las medias (+ las variables originales de X)
X_cre = pd.concat([X, Xm], axis=1)

# Paso 4: Estimar Random Effects sobre X aumentado
cre = lmp.RandomEffects(y, X_cre).fit(cov_type='robust')
print(cre)
```

RandomEffects Estimation Summary

```
=====
Dep. Variable:          workplaces    R-squared:                0.3489
Estimator:              RandomEffects  R-squared (Between):      0.4474
No. Observations:      12040          R-squared (Within):       0.3482
Date:                  Mon, May 25 2026  R-squared (Overall):      0.3622
Time:                  00:04:30          Log-likelihood            -4.334e+04
```

Cov. Estimator:	Robust	F-statistic:	460.30
Entities:	86	P-value	0.0000
Avg Obs:	140.00	Distribution:	F(14,12025)
Min Obs:	140.00		
Max Obs:	140.00	F-statistic (robust):	306.36
		P-value	0.0000
Time periods:	140	Distribution:	F(14,12025)
Avg Obs:	86.000		
Min Obs:	86.000		
Max Obs:	86.000		

Parameter Estimates

		Parameter	Std. Err.	T-stat	P-value
Lower CI	Upper CI				

const		1.017e+04	644.71	15.775	0.0000
8906.5	1.143e+04				
Valor_Stringency_Index		-0.5089	0.0255	-19.958	0.0000
-0.5589	-0.4589				
Valor_Containment_Health_index		0.5498	0.0445	12.364	0.0000
0.4626	0.6369				
log_cases		-0.2731	0.0313	-8.7180	0.0000
-0.3345	-0.2117				
workplace_closing		-1.2583	0.2899	-4.3410	0.0000
-1.8265	-0.6901				
age_dependency		22.407	7.8633	2.8495	0.0044
6.9931	37.820				
unemp		-0.0510	0.1035	-0.4932	0.6219
-0.2539	0.1518				
foreigners		-0.2768	0.1580	-1.7515	0.0799
-0.5865	0.0330				
industry		-17.240	11.013	-1.5655	0.1175
-38.827	4.3467				
week		0.1519	0.0067	22.665	0.0000
0.1388	0.1651				
year		-4.9985	0.3193	-15.656	0.0000
-5.6244	-4.3727				
m_Valor_Stringency_Index		1.5919	0.4243	3.7515	0.0002
0.7601	2.4237				
m_Valor_Containment_Health_index		-3.4771	0.9842	-3.5329	0.0004
-5.4063	-1.5479				
m_log_cases		-19.482	9.1027	-2.1403	0.0324
-37.325	-1.6398				
m_workplace_closing		69.297	26.014	2.6638	0.0077

18.306 120.29

=====

```
[27]: # Test de Mundlak: significancia de los coeficientes de las variables de media
mean_vars = [c for c in cre.params.index if c.startswith('m_')]

print('=== Test de Mundlak ===')
print(f'{{'Variable':<35}} {{'Coeficiente':>14}} {{'P-valor':>10}} {{'Significativo?':
    ↳>14}}")
print('-' * 78)
significant_count = 0
for v in mean_vars:
    coef = cre.params[v]
    pv = cre.pvalues[v]
    sig = '*** (Sí)' if pv < 0.01 else ('** (Sí)' if pv < 0.05 else 'No')
    if pv < 0.05: significant_count += 1
    print(f'{{v:<35}} {{coef:>14.4f}} {{pv:>10.4f}} {{sig:>14}}')

print()
print(f'Variables significativas: {significant_count}/{len(mean_vars)}')
if significant_count > 0:
    print('Conclusión: Las medias son significativas → el supuesto de RE está_
    ↳violado')
    print('→ Los efectos individuales están correlacionados con los regresores.
    ↳')
    print('→ CRE (o FE) es la especificación correcta.')
else:
    print('Conclusión: Las medias no son significativas → RE simple podría ser_
    ↳adecuado.')
```

=== Test de Mundlak ===

Variable	Coeficiente	P-valor	Significativo?
m_Valor_Stringency_Index	1.5919	0.0002	*** (Sí)
m_Valor_Containment_Health_index	-3.4771	0.0004	*** (Sí)
m_log_cases	-19.4825	0.0324	** (Sí)
m_workplace_closing	69.2970	0.0077	*** (Sí)

Variables significativas: 4/4

Conclusión: Las medias son significativas → el supuesto de RE está violado

→ Los efectos individuales están correlacionados con los regresores.

→ CRE (o FE) es la especificación correcta.

1.7.1 Interpretación CRE / Test de Mundlak

1. Coeficientes within (variables originales): el coeficiente de Valor_Stringency_Index en CRE debería coincidir con el del FE, ya que ambos capturan la misma variación temporal dentro

de ciudad. Esto confirma que el estimador within es consistente independiente del modelo usado.

2. Coeficientes between (variables de media, $m_{\cdot}$): el coeficiente de $m_{\text{Valor_Stringency_Index}}$ captura si las ciudades con un Stringency promedio más alto a lo largo del período tienen sistemáticamente diferente movilidad. Si es positivo y significativo, sugiere que las ciudades que más restringieron eran las que tenían economías más abiertas de base (turismo, servicios), lo que es un efecto de selección, no causal.

3. Test de Mundlak: si los coeficientes de las medias ($m_{\cdot}$) son significativos, el supuesto de RE simple está violado y el modelo CRE es el correcto. Si no son significativos, RE podría ser suficiente. Con datos COVID-19 esperamos que sí sean significativos, ya que las ciudades con distintos niveles promedio de restricciones son estructuralmente distintas.

Conclusión: CRE es preferible a FE puro porque además de recuperar el mismo estimador within, nos permite estimar el efecto de los demográficos time-invariant y separar el efecto causal (within) del efecto de selección (between).

1.8 Pregunta 7: Selección del Modelo Final y Conclusiones

```
[28]: # Tabla comparativa completa de los cuatro modelos
print('=== Comparación Final: Todos los Modelos ===')
print(lmp.compare({'Pooled OLS': mco, 'FE': fe, 'RE': re, 'CRE': cre}))
```

=== Comparación Final: Todos los Modelos ===

Model Comparison

		=====	
=====			
		Pooled OLS	FE
RE	CRE		
-----		-----	
Dep. Variable		workplaces	workplaces
workplaces	workplaces		
Estimator		PanelOLS	PanelOLS
RandomEffects	RandomEffects		
No. Observations		12040	12040
12040	12040		
Cov. Est.		Robust	Robust
Robust	Robust		
R-squared		0.3433	0.3482
0.3460	0.3489		
R-Squared (Within)		0.3427	0.3482
0.3474	0.3482		
R-Squared (Between)		0.3469	-0.5593
0.1603	0.4474		
R-Squared (Overall)		0.3433	0.2202
0.3210	0.3622		
F-statistic		628.76	1064.0

636.43	460.30		
P-value (F-stat)		0.0000	0.0000
0.0000	0.0000		
=====	=====	=====	=====
const		9304.4	1.011e+04
9769.6	1.017e+04	(14.317)	(15.565)
(15.536)	(15.775)		
Valor_Stringency_Index		-0.3561	-0.5041
-0.4645	-0.5089	(-19.978)	(-19.842)
(-21.100)	(-19.958)		
Valor_Containment_Health_index		0.2541	0.5425
0.4502	0.5498	(14.176)	(12.225)
(13.457)	(12.364)		
log_cases		-0.0971	-0.2733
-0.2060	-0.2731	(-3.3403)	(-8.6976)
(-6.9514)	(-8.7180)		
workplace_closing		-0.8997	-1.2561
-1.0723	-1.2583	(-3.0943)	(-4.3406)
(-3.8133)	(-4.3410)		
age_dependency		6.7255	
-8.1296	22.407	(4.3718)	
(-1.2901)	(2.8495)		
unemp		-0.0309	
-0.2345	-0.0510	(-1.6878)	
(-3.1654)	(-0.4932)		
foreigners		-0.4016	
-0.4912	-0.2768	(-10.781)	
(-3.2556)	(-1.7515)		
industry		-6.2798	
-11.219	-17.240	(-2.9273)	
(-1.1955)	(-1.5655)		
week		0.1579	0.1522
0.1528	0.1519	(22.713)	(22.563)
(22.920)	(22.665)		
year		-4.6171	-5.0173
-4.8415	-4.9985	(-14.348)	(-15.595)

```

(-15.555)      (-15.656)
m_Valor_Stringency_Index
1.5919
          (3.7515)
m_Valor_Containment_Health_index
-3.4771
          (-3.5329)
m_log_cases
-19.482
          (-2.1403)
m_workplace_closing
69.297
          (2.6638)

```

```

=====
=====
Effects                                             Entity
-----
-----

```

T-stats reported in parentheses

1.8.1 Selección del Modelo Final

Criterio	Resultado	Decisión
F-test poolabilidad (FE)	$p < 0.001$	Los efectos fijos de ciudad son relevantes → descartar Pooled OLS
Test de Hausman	$p < 0.05$	RE está sesgado → descartar RE simple
Test de Mundlak (CRE)	medias significativas	Confirma que hay correlación entre efectos individuales y regresores
CRE vs FE	Mismo estimador within + estima demográficos	CRE es el modelo preferido

El **modelo CRE** es el más adecuado porque: (1) controla la heterogeneidad de ciudad igual que FE, (2) permite estimar el efecto de las variables demográficas que FE pierde, y (3) separa el efecto within (causal) del efecto between (selección).

1.8.2 Conclusiones económicas

1. **Efecto de las restricciones:** Un aumento de 10 puntos en el Stringency Index redujo la movilidad laboral en aproximadamente **5 pp** dentro de cada ciudad (coeficiente FE/CRE). Este es el efecto causal más creíble, limpio de diferencias estructurales entre ciudades.

2. **Órdenes de cierre laboral:** `workplace_closing` tiene un efecto adicional significativo (-1.26 pp por nivel) por encima del Stringency general. Las políticas específicas de cierre de lugares de trabajo importan más allá del índice agregado.
3. **Comportamiento voluntario:** `log_cases` es negativo y significativo en FE, lo que indica que las personas también reducen movilidad espontáneamente ante más casos, incluso sin restricciones formales.
4. **Efecto de selección (between en CRE):** si `m_Valor_Stringency_Index` es positivo, las ciudades con restricciones más intensas en promedio tenían mayor movilidad de base — son ciudades de economías más abiertas que necesitaron más intervención. Este no es un efecto causal sino una diferencia estructural entre tipos de ciudades.
5. **Endogeneidad residual:** incluso con CRE, persiste el riesgo de que las restricciones se endurezcan justo cuando la movilidad ya estaba cayendo (causalidad inversa temporal). Esto se aborda en la Pregunta 8 con el Control Sintético.

Pre-
gunta
8:
Con-
trol
sin-
tético

El
**Con-
trol
sin-
tético**

es un
método
alter-
na-
tivo
de
iden-
tifi-
cación
causal.

En
vez
de
com-
parar
cada
ciu-
dad
con-
sigo
misma
antes
y de-
spués
de
las
re-
stric-
ciones
(como
hace
FE),
con-
struye
un
*con-
trafac-
tual*
para
una
ciu-
dad
es-
pecí-
fica

us-
ando

Pregunta:

¿Cuánto
re-
dujo
el
lock-
down
es-
pañol
la
movil-
idad
labo-
ral
de
Barcelona?

Ciudad tratada: Barcelona (ES002C) - El Stringency Index de España salta de ~11 a más de 50 en la semana 5 (16 de marzo 2020), con la declaración del estado de alarma nacional. - Hay un quiebre claro y abrupto → evento de tratamiento bien definido.

Donor pool: ciudades alemanas (39 ciudades) - Alemania no tuvo lockdown formal (Stringency = 0 todo el período) → sirven como contrafactual de “cómo evolucionaría Barcelona sin restricciones”.

```
[46]: from pysyncon import Dataprep, Synth

# Filtrar al primer año (semanas 1-52)
# Semana 5 = 16 de marzo 2020 (inicio del lockdown español)
df_synth = df[df['week'] <= 52].copy()

# pysyncon necesita formato LARGO: cada fila = una ciudad en un período
# (no formato ancho donde las ciudades son columnas)
df_long = df_synth[['NAME', 'week', 'workplaces']].copy()

print('Shape del dataset long:', df_long.shape)
print('Semanas:', df_long['week'].min(), 'a', df_long['week'].max())
print('Ciudades únicas:', df_long['NAME'].nunique())
```

Shape del dataset long: (4472, 3)

Semanas: 1 a 52

Ciudades únicas: 86

```
[47]: # Identificar Barcelona y ciudades alemanas
barcelona_name = df[df['CODE'] == 'ES002C']['NAME'].unique()[0]
german_names    = df[df['country'] == 'DE']['NAME'].unique().tolist()
```

```

print('Ciudad tratada:', barcelona_name)
print(f'Donor pool: {len(german_names)} ciudades alemanas')
print('Período pre-tratamiento: semanas 1-4')
print('Período post-tratamiento: semanas 5-52')

```

Ciudad tratada: Barcelona
 Donor pool: 39 ciudades alemanas
 Período pre-tratamiento: semanas 1-4
 Período post-tratamiento: semanas 5-52

```

[48]: # Configuración del Dataprep
# Nota: 'time_plot' no va en Dataprep - se pasa directamente a path_plot/
      ↪ gaps_plot
dataprep = Dataprep(
    foo=df_long,
    predictors=['workplaces'],
    predictors_op='mean',
    time_predictors_prior=list(range(1, 5)),    # Semanas 1-4: pre-tratamiento
    dependent='workplaces',
    unit_variable='NAME',
    time_variable='week',
    treatment_identifier=barcelona_name,
    controls_identifier=german_names,
    time_optimize_ssr=list(range(1, 5)),        # Minimizar MSPE en semanas 1-4
)

# Ajuste del control sintético
synth = Synth()
synth.fit(dataprep)
print('Control sintético ajustado exitosamente.')

```


Control sintético ajustado exitosamente.

```

[55]: # Gráfico 1: Trayectorias (Barcelona real vs Barcelona sintética)
# synth.path_plot() crea su propia figura - le pasamos el ax que queremos usar
fig, ax = plt.subplots(figsize=(13, 5))
synth.path_plot(
    time_period=list(range(1, 53)),
    treatment_time=5,
)
ax.set_title('Barcelona Real vs. Control Sintético - Movilidad Laboral',
      ↪ fontsize=13)
ax.set_xlabel('Semana (2020-2021)')
ax.set_ylabel('Movilidad Laboral (% de-trended)')
ax.axvline(x=5, color='red', linestyle='--', linewidth=1.5, label='Inicio
      ↪ Lockdown (Semana 5)')
ax.legend()
ax.grid(alpha=0.3)


```

```
plt.tight_layout()
plt.show()
```



<Figure size 640x480 with 0 Axes>

```
[56]: # Gráfico 2: Brecha (efecto causal estimado = Barcelona real - Barcelona
      ↪ sintética)
fig, ax = plt.subplots(figsize=(13, 5))
synth.gaps_plot(
    time_period=list(range(1, 53)),
    treatment_time=5,
)
ax.set_title('Efecto Causal Estimado: Barcelona - Control Sintético',
            ↪ fontsize=13)
ax.set_xlabel('Semana (2020-2021)')
ax.set_ylabel('Diferencia en Movilidad Laboral (pp)')
ax.axhline(y=0, color='black', linestyle='--', linewidth=0.8)
ax.axvline(x=5, color='red', linestyle='--', linewidth=1.5, label='Inicio
      ↪ Lockdown (Semana 5)')
ax.legend()
ax.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```



<Figure size 640x480 with 0 Axes>

```
[51]: # Pesos del control sintético
# synth.W es un numpy array - convertirlo a Series usando los nombres del donor_
      ↳ pool
print('=== Pesos del Control Sintético (W) ===')
weights = pd.Series(synth.W.flatten(), index=german_names).
      ↳ sort_values(ascending=False)
weights_nonzero = weights[weights > 0.001]

print('Ciudades con peso > 0.001:')
for city, w in weights_nonzero.items():
    print(f' {city:<35}: {w:.4f}  ({w*100:.1f}%)')

print()
print(f'Suma total de pesos: {weights.sum():.4f}')
print(f'Ciudades con peso positivo: {(weights > 0.001).sum()} de_
      ↳ {len(weights)}')
```

=== Pesos del Control Sintético (W) ===

Ciudades con peso > 0.001:

Berlin	: 0.0318	(3.2%)
Hannover	: 0.0307	(3.1%)
Braunschweig	: 0.0307	(3.1%)
Bremen	: 0.0293	(2.9%)
Kiel	: 0.0293	(2.9%)
Lübeck	: 0.0293	(2.9%)
Magdeburg	: 0.0293	(2.9%)
Halle an der Saale	: 0.0293	(2.9%)
Erfurt	: 0.0263	(2.6%)
Frankfurt am Main	: 0.0262	(2.6%)
Kassel	: 0.0262	(2.6%)

Wiesbaden	:	0.0262	(2.6%)
Hamburg	:	0.0248	(2.5%)
Karlsruhe	:	0.0242	(2.4%)
Freiburg im Breisgau	:	0.0242	(2.4%)
Dresden	:	0.0242	(2.4%)
Bonn	:	0.0242	(2.4%)
Chemnitz	:	0.0242	(2.4%)
Oberhausen	:	0.0242	(2.4%)
Düsseldorf	:	0.0242	(2.4%)
Nürnberg	:	0.0242	(2.4%)
Bochum	:	0.0242	(2.4%)
Wuppertal	:	0.0242	(2.4%)
Rostock	:	0.0242	(2.4%)
Augsburg	:	0.0242	(2.4%)
Köln	:	0.0242	(2.4%)
Leipzig	:	0.0242	(2.4%)
Mannheim	:	0.0242	(2.4%)
München	:	0.0242	(2.4%)
Essen	:	0.0242	(2.4%)
Bielefeld	:	0.0242	(2.4%)
Krefeld	:	0.0242	(2.4%)
Aachen	:	0.0242	(2.4%)
Münster	:	0.0242	(2.4%)
Gelsenkirchen	:	0.0242	(2.4%)
Dortmund	:	0.0242	(2.4%)
Mönchengladbach	:	0.0242	(2.4%)
Stuttgart	:	0.0242	(2.4%)
Duisburg	:	0.0242	(2.4%)

Suma total de pesos: 1.0000

Ciudades con peso positivo: 39 de 39

1.8.3 Interpretación Control Sintético

1. Gráfico de trayectorias (path plot): - **Período pre-tratamiento (semanas 1–4):** si la Barcelona real y la sintética tienen trayectorias similares, el match es válido y el contrafactual es creíble. - **Período post-tratamiento (semanas 5+):** la brecha que se abre entre ambas líneas es el efecto causal estimado del lockdown. Una caída de Barcelona por debajo del sintético indica que las restricciones redujeron la movilidad por encima de lo que habría ocurrido naturalmente.

2. Gráfico de brecha (gaps plot): muestra directamente esa diferencia (Barcelona real — Barcelona sintética) semana a semana. La brecha negativa en las primeras semanas post-lockdown refleja el impacto inicial de las restricciones. La recuperación gradual hacia cero muestra la adaptación a lo largo del tiempo.

3. Pesos del sintético (W): las ciudades alemanas con mayor peso son las que mejor reproducen el patrón de movilidad pre-pandemia de Barcelona. Reportar cuáles son permite interpretar qué tipo de ciudades forman el contrafactual.

4. Limitación principal: el período pre-tratamiento es de solo **4 semanas**, lo que es muy poco para construir un buen match. Idealmente necesitaríamos al menos varios meses de datos previos a la pandemia para que el MSPE minimizado fuera realmente informativo. Con 4 semanas, el ajuste pre-tratamiento puede ser casi aleatorio, lo que reduce la credibilidad del contrafactual.

5. Comparación con el análisis de panel: mientras FE y CRE estiman el efecto promedio sobre todas las ciudades, el control sintético estima el efecto para Barcelona específicamente. Ambos enfoques son complementarios y, si apuntan en la misma dirección, refuerzan la conclusión de que las restricciones sí redujeron la movilidad laboral de forma significativa.